上交所医疗器械财报 RAG：R01–R10 评测结论

17 份 2026 年半年度报告（4657 chunk）｜表头增强索引 **index/header**｜混合召回（BM25 + FAISS）→ RRF 融合 → Top-6 证据 → **deepseek-chat**（temperature 0.1）
出报告日期：2026-09-28｜判分为人判（review_questions_R01-R10.json），非脚本计算

一、一句话结论

> 10 道题答对 **7 道（70.0%）**：单公司题 7/8（87.5%）、跨公司题 **0/2（0%）**。把逐路召回名次与判定结果交叉后，得到一条没有例外的规律 —— **gold 块进了最终 Top-6 证据的 7 道题，7 道全对；gold 块掉出 Top-6 的 3 道题，3 道全错。**3 道错题里没有一道是模型答错：在证据够的题上它答得准，在证据缺的题上它明确说「证据里没有」而没有编造。

因此这份结论的核心不是「模型行不行」，而是**召回在什么题型上会漏，以及为什么漏。**

二、总览

指标	结果	说明
总准确率	**7/10 = 70.0%**	已判定 10 题，无「未判」
单公司题（R01–R08）	**7/8 = 87.5%**	错的是 R05（经营现金流）
跨公司题（R09–R10）	**0/2 = 0.0%**	R09 两家比、R10 五家比，均未答全
引用越界编号	0 次	没有一处引用不存在的证据编号
凭空数字	0 处	回答里的数字除股票代码与 3 处自算差值外，全部逐字出自证据

错误类型分布（用户给定的 E1–E10）

错误类型	名称	数量	涉及题目
E1	错误公司	0	—
E2	错误页面	0	—
E3	文本切块错误	0	—
E4	表格解析错误	0	—
E5	跨页召回失败	0	—
E6	**跨公司召回不足**	**2**	**R09、R10**
E7	模型理解错误	0	—
E8	数字计算错误	0	—
E9	引用错误	0	—
E10	**其他**	**1**	**R05**
合计		**3**	**R05、R09、R10**

E1–E5、E7–E9 **八类一个都没出现**：没有认错公司、没有引错页码、没有切块或表格解析缺陷、没有模型理解错、没有算错数、没有编造引用。错题全部集中在召回侧。

三、哪类题答得好

3.1 定性叙述题：3/3，全对，且答得很完整

R06（收入增量来自哪里）、R07（核心业务与主要产品）、R08（毛利率波动风险受哪些因素影响）三题全对。这三题的共同点是**答案集中在一个正文块里**，而且那个块**本身含有公司名和密集的主题词**：

题	gold 块	BM25 名次	向量名次	作答要点
R06	688271-0038	#1	#2	「海外业务持续放量 + 国内份额逆势提升」逐字答中，并补充国内收入 52.87 亿元/+8.49%、份额 +1.7 个百分点
R07	688013-0012	#6	池外	核心业务三句 + 有源/无源两大类及各自子类全中
R08	688617-0033	#1	#1	集采政策、产品销售结构、市场竞争格局三项全中，并给出后果表述

值得注意 R07：它的 gold 在**向量路完全没进 Top-20**，只靠 BM25 第 6 名进来 —— 这说明两路召回在这里是互补的，任一路单独漏掉都不致命。

3.2 单点数值题：4/5，靠「同一数字在别处还有一份」救回来的

R01（营收）、R02（归母净利润）、R03（毛利率）、R04（研发投入）全对。其中 R01、R02、R04 的 gold 块**本身也没被融合保进 Top-6**（R01 的 gold 在 BM25 第 20 名、向量第 10 名；R02 在第 9/第 6 名），但它们仍然答对了 —— 因为**同一个数字在半年报里有冗余表述**：主要会计数据表里的营收/净利润，在第八节合并利润表、第三节管理层讨论与分析里还会再出现一次，模型从那些块里取到了同值。

R04 是这一类的正面样板：两条 gold（研发投入情况表 688351-0024、主要财务指标表 688351-0008）**双双进了证据并都被引用**，金额、占比、同比三个数字全中，还主动区分了母公司口径。

3.3 一句话概括「好」的条件

> 答案落在**含公司名的正文块**里，或者答案数字在语料里有**冗余副本** —— 满足其一就稳。反之（答案只存在于某一张不含公司名的表格里、且无副本）就会翻车，见下一节。

四、哪类题翻车

4.1 跨公司题：0/2 —— 全军覆没

R09（安图生物 vs 万东医疗）与 R10（拱东 / 爱博 / 圣湘 / 祥生 / 三友 五家排序）都要求**多家公司的同一指标同时出现在证据里**，而最终证据只有 Top-6 条。两题各答对一部分：

题	答对了什么	缺了什么
R09	万东医疗 −91,667,605.80 元、上年同期 51,298,644.68 元、同比 −278.69%，全对	安图生物归母净利润（gold 603658-0008：BM25 第 16 名、向量池外，融合后被挤出 Top-6）
R10	拱东医疗 588,022,932.18 元（**没踩万元陷阱**）、祥生医疗 241,448,492.64 元	爱博医疗、圣湘生物、三友医疗三家**两路全在池外**（688289-0008 与 688085-0008 的 BM25 全库 0 命中）

R10 的模型行为值得单独肯定：证据只够 2/5，它**没有硬排一个顺序**，而是列出「缺少爱博医疗、圣湘生物、三友医疗三家公司的任何营业收入数据」，并给出已确认的两家数字后拒答。按「题目问到的都要答到」的严格口径这题记错，但它的拒答是对的。

4.2 单公司题里唯一翻车的：R05（经营现金流）

这题的特殊之处是**数对了一半**：经营活动现金流量净额 160,232,989.24 元、上年同期 33,854,199.97 元**完全正确** —— 模型从「现金流量表补充资料」（603309-0209）取到了与 gold 同值的数字。缺的是**公司披露的同比 +373.30%**：模型说「证据中未直接给出同比变化」，改为自算增减额 126,378,789.27 元（减法正确）。

为什么 R01/R02 靠冗余救回来了、R05 没有？因为**冗余救不了「只在一处存在」的信息**。净额本身在财务报告里有第二份，但那个 +373.30% 的同比比例**只写在 603309-0008（第二节 主要会计数据表）那一张表里**，而它没进证据。

判定边界已如实记录：若按宽松口径把「自算的绝对增减额」也算作「同比变化」，本题可判对 —— 那样单公司就是 8/8、总准确率 80%。本报告与 errors.xlsx 采用与旧套一致的严格口径，并在原因栏写明。

五、为什么：两种机理，一个根因

5.1 铁律：gold 进没进最终证据，与对错 10/10 对应

逐题把「每条 gold 在 BM25 / 向量各自 Top-20 里的名次」量出来，与判定对照：

题	gold 块	BM25	向量	进最终证据	判定
R01	600587-0007	#20	#10	是	√ 答对
R02	603387-0009	#9	#6	是	√ 答对
R03	688016-0031	#1	#5	是	√ 答对
R04	688351-0008	#20	#3	是	√ 答对
	688351-0024	#1	#1	是	
R05	603309-0008	池外	#10	**否**	× 答错
R06	688271-0038	#1	#2	是	√ 答对
R07	688013-0012	#6	池外	是	√ 答对
R08	688617-0033	#1	#1	是	√ 答对
R09	600055-0007	#12	#5	是	× 答错
	603658-0008	#16	池外	**否**	
R10	605369-0009	池外	#14	**否**	× 答错
	688050-0007	池外	池外	**否**	
	688085-0008	池外	池外	**否**	
	688289-0008	池外	池外	**否**	
	688358-0008	池外	#2	是	

> 把「gold 有缺口」的题挑出来：**R05、R09、R10** —— 正好就是答错的 3 题；「gold 全覆盖」的 **R01、R02、R03、R04、R06、R07、R08** 7 题则全部答对。这不是相关，是**一一对应**：召回决定对错，生成层在这一轮里没有失手。

5.2 机理一：融合截断（R05、R09）—— 池子里有，但被挤出 Top-6

R05 的 gold 在**向量路第 10 名**、R09 安图那一条在 **BM25 第 16 名**，两条都**已经进了 k=20 的候选池**，是 RRF 融合之后的排序把它们挤出了 Top-6。这意味着**单纯调大召回深度救不回来** —— 池子再深，只要融合排序把它们排在 6 名之后就没有用。这个机理在旧评测集里已经对旗舰题 Q01 实测证伪过一次（「调大深度就能救」），这里是同一机理在新题面上的复现。

5.3 机理二：候选池深度不足（R10）—— 从头就没进池子

R10 的 5 张表里，只有祥生医疗那张进了池（向量第 2 名），拱东那张进到向量第 14 名但没保住；另外三家（爱博 688050-0007、圣湘 688289-0008、三友 688085-0008）**两路都在 Top-20 之外**，其中圣湘与三友那两张表的 **BM25 在全库 4657 条里 0 命中**。这一类和 R05/R09 不同：不是排序问题，是**根本没被检索到**。

5.4 共同根因：表格块里没有公司名

三种失败指向同一个事实：**17 家公司的「主要会计数据」表正文几乎同构，而且表内不含公司名**。问「维力医疗的现金流」，BM25 里分值最高的判别词恰恰是「维力」这个高 IDF 词，而它出现在正文的散文里、不出现在那张表里 —— 于是同名结构的表格输给了所有提到公司的散文块。向量侧同理：17 张几乎一样的表，模型无从分辨哪张属于哪家。

R01/R02/R04 之所以没被这个根因击倒，是因为它们的答案数字在语料里有**冗余副本**（第八节合并利润表、第三节转述），绕开了那张表；R05 缺的同比比例、R09/R10 缺的对家数字，都**只在那张表里有**，绕不开。

5.5 已经有的对症手段，以及它为什么这次没生效

项目里本来就有一条针对「跨公司取同一张表」的**结构化表组路由**（src/retrieval/structured.py）：按语料的硬结构确定性地取出 17 家公司各自的「主要会计数据」表，曾经做到 17/17 家公司覆盖。但它有一个前置判据 —— **只在问题里没有点名公司时才触发**（判据见 structured.py 顶部）。R09 点名了 2 家、R10 点名了 5 家，所以这条路**两题都没有走**，退回了纯相似度检索。这是一个**接口缺口，不是能力缺口。**

六、逐题结果一览

题	主题	题型	gold 名次（BM25/向量）	判定	错误类型
R01	营业收入	单公司	600587-0007 #20/#10	√ 答对	—
R02	净利润	单公司	603387-0009 #9/#6	√ 答对	—
R03	毛利率/盈利能力	单公司	688016-0031 #1/#5	√ 答对	—
R04	研发投入	单公司	688351-0008 #20/#3； 688351-0024 #1/#1	√ 答对	—
R05	经营现金流	单公司	603309-0008 池外/#10	× 答错	E10 其他
R06	主要业务变化	单公司	688271-0038 #1/#2	√ 答对	—
R07	主要产品	单公司	688013-0012 #6/池外	√ 答对	—
R08	风险因素	单公司	688617-0033 #1/#1	√ 答对	—
R09	两家公司财务指标比较	跨公司	600055-0007 #12/#5； 603658-0008 #16/池外	× 答错	E6 跨公司召回不足
R10	多家公司综合比较	跨公司	605369-0009 池外/#14； 688050-0007 池外/池外； 688085-0008 池外/池外； 688289-0008 池外/池外； 688358-0008 池外/#2	× 答错	E6 跨公司召回不足

注：名次是每题 gold 块在 BM25 / 向量各自 Top-20 里的位置，「池外」= 未进 Top-20。完整回答原文、全部 Top-6 证据原文见 evaluation/results.xlsx 与 generation_questions_R01-R10.json。

七、改进方向（按证据，不按猜测）

7.1 跨公司比较题接入结构化表组

把「点名了 N 家公司、要横向比同一指标」这一类也接到 structured.py 的表组路由上（按识别出的公司集合去取各自的「主要会计数据」表），而不是退回相似度检索。这是针对 R09/R10 的直接修法，也是这次失败暴露出的唯一接口缺口。

7.2 给融合加「每家公司保底一条」

R05、R09 的共同机理是池内 gold 被融合挤出 Top-6。修法不在加深池子，而在融合环节：对识别到的每家公司，从候选池里保底保留其最高分的那条块再排序。这条对症融合截断，且不改变「不问公司名」的题（那类题识别不到具体公司）。

7.3 不要换更大的模型

3 道错题没有一道是模型答错：证据够时答得准，证据缺时明确说没有、不编数。R09 里它甚至主动拒绝用母公司净利润顶替归母净利润。换模型不解决这里的任何一题。

八、口径与产物

口径：表头增强索引 index/header；混合召回 = BM25（jieba）+ FAISS 余弦，各取 Top-20 候选 → RRF 融合（k=60）→ 公司/章节软加权 → 取 Top-6 证据；生成 = deepseek-chat，temperature 0.1，证据不足须明说。**这是一次采样的结果**，同一题换一轮表述会变，不能与旧评测集（另一套 10 题）的 7/10 相加或平均。

文件	内容
evaluation/results.xlsx	逐题 11 栏完整记录（含 BM25/向量逐路召回、最终 chunk、引用页码、回答、标准答案、判定、错误类型、错误原因） + 逐题证据明细 60 条 + 口径与汇总
evaluation/errors.xlsx	错题台账（含「缺哪块 gold」） + E1–E10 类型统计（含数量为 0 的类型）
evaluation/results/review_questions_R01-R10.json	逐题判定（人判，两份表的输入）
evaluation/results/generation_questions_R01-R10.json	原始记录：全部证据原文与回答原文、逐路召回、token 用量
evaluation/questions.xlsx	题目与标准答案（R01–R10，8 单公司 + 2 跨公司）

复现：python scripts/eval_generation.py --dataset evaluation/datasets/questions.jsonl --index ./index/header
python scripts/build_results_xlsx.py
python scripts/build_conclusion_pdf.py